

面向 AI 智能体安全诊断的认知先验残差贝叶斯网络

李明锋¹ 李欣^{1,2,3} 李满^{1,2,3} 陆开¹ 彭奕杰¹ 石家和¹

1. 中国人民公安大学信息安全学院 北京 100038
2. 公安部安全防范技术与风险评估公安部重点实验室 北京 100038
3. 中国人民公安大学大数据战略研究中心 北京 100038
(2025211431@stu.ppsuc.edu.cn)

摘要：大语言模型驱动的 AI 智能体在高风险场景中面临提示注入、目标劫持等认知操控攻击，现有安全检测方法以端到端黑盒分类为主，能够判定轨迹是否安全，却难以定位智能体行为失准的具体环节。文章提出基于智能体认知先验建模的残差贝叶斯网络 CP-RBN，受规范化智能体理论与双过程认知理论启发，将智能体的安全状态分解为意图对齐、应答合规与操作风险三个因果递进的认知维度，并针对多步交互中的信念持续性与认知短路问题在网络结构中嵌入拓扑跳转连接与时序惯性通道。在 ATBench、R-Judge 与 ASSEBench 三项基准上 CP-RBN 取得 84.3% 的宏平均 F1，并在保持白盒推理结构的同时接近最优诊断型护栏基线。同时，CP-RBN 对不安全样本实现 100% 归因覆盖，可对齐诊断样本上的平均一致率达 98.2%，平均 EIR@50% 达 90.4%，体现出模型本身的可解释诊断与早期预警能力。

关键词：认知先验建模；贝叶斯网络；智能体安全；残差学习；因果推理

中图法分类号 TP18

Cognitive-Prior Residual Bayesian Network for AI Agent Safety Diagnosis

Li Mingfeng¹ Li Xin^{1,2,3} Li Man^{1,2,3} Lu Kai¹ Peng Yijie¹ Shi Jiahe¹

1. People's Public Security University of China School of Information and Network Security, Beijing, 10038
2. Ministry of Public Security Key Laboratory of Security Technology and Risk Assessment, Beijing, 10038
3. Big Data Strategy Research Center of the People's Public Security University of China, Beijing, 10038

Abstract: Large language model driven AI agents face cognitive manipulation attacks such as prompt injection and goal hijacking in high-risk scenarios. Existing safety detection methods mainly rely on end-to-end black-box classification. They can determine whether an agent trajectory is safe, but often fail to locate the specific stage at which agent behavior deviates from the intended goal or safety

收稿日期：xxxx-xx-xx；修回日期：xxxx-xx-xx

通信作者：李欣（lixin@ppsuc.edu.cn）

基金项目：中国人民公安大学研究生科研创新重点项目(2026YJSKY008)

constraints. To address this limitation, the study developed a Cognitive-Prior Residual Bayesian Network, abbreviated as CP-RBN, for white-box safety diagnosis of AI agents. Inspired by normative agent theory and dual-process cognitive theory, CP-RBN decomposed agent safety states into three causally progressive cognitive dimensions: intent alignment, response compliance, and operational risk. It further embedded topological skip connections and temporal inertia channels into the Bayesian network structure to model cognitive shortcuts and belief persistence in multi-step interactions. Experiments were conducted on ATBench, R-Judge, and ASSEBench. CP-RBN achieved a macro-average F1 score of 84.3% and approached the best diagnostic guardrail baseline while maintaining a white-box reasoning structure. It also achieved 100% attribution coverage for unsafe samples, reached an average consistency of 98.2% on diagnostically aligned samples, and obtained an average Early Intervention Rate at 50% trajectory truncation of 90.4%. These results indicate that CP-RBN provides competitive safety detection while preserving structured interpretability. The model supports causal diagnosis of unsafe trajectories and provides early warning during the formation of attack trajectories.

Keywords: cognitive prior modeling; Bayesian network; AI agent safety; residual learning; causal reasoning

1 引言

大语言模型驱动的 AI 智能体已广泛部署于代码生成、数据分析和自动化运维等场景^[1]。这类智能体能够自主规划任务、调用外部工具并与环境交互，其操作能力超过传统对话式 AI。然而，这种自主性也引入了新的攻击面，攻击者可通过提示注入污染智能体的认知体系^[2]，通过目标劫持偏转其任务执行方向^[3]，或通过隐蔽行为引导使其在表面合规的掩盖下执行危险操作^[4]。与传统网络攻击不同，这类威胁的核心特征在于攻击目标从系统漏洞和数据完整性转向了智能体的认知过程，包括其对任务目标的理解、对安全边界的遵从、以及对操作后果的评估。

为应对上述威胁，安全检测方向在近三年间沿规则驱动与模型驱动两条路线快速演进。2023 年，NeMo Guardrails^[5]通过领域专用语言 Colang 以可编程中间件定义对话边界与安全约束，代表了确定性规则路线的起点；Llama Guard^[6]则率先将安全分类建模为指令微调的 LLM 推理任务，开启了基于大模型的护栏范式。2025 年，两条路线均从单轮对话向智能

体轨迹级安全深化。在规则侧，ShieldAgent^[7]从策略文档中提取可验证规则并组织为概率规则电路，通过形式化验证实现动作级约束检查；DRIFT^[8]进一步构建了安全规划器、动态验证器与注入隔离器三层运行时监控架构。在模型侧，护栏模型的检测粒度持续提升。2026 年，AgentDoG^[9]在 ATBench、R-Judge 和 ASSEBench 上均取得同期领先性能，并具备输出风险来源与失败模式等诊断标签的能力。

然而，上述两条路线各有局限。规则系统的表达能力受限于人工先验的编码粒度，关键词匹配易被语义改写规避，动作模式校验依赖预定义违规模板，且规则间相互独立，无法建模认知维度之间的因果依赖。基于 LLM 的护栏模型虽检测精度不断提升，但其判决过程仍是端到端黑盒分类。当一条轨迹被判定为不安全时，这类模型缺乏对受攻击认知环节的定位能力，难以为后续防御设计提供直接指导。两条路线的共同不足在于，它们能够回答一条轨迹是否安全，却无法解释不安全状态如何产生。对于安全工程实践而言，理解攻击逐步瓦解智

能体认知防线的具体路径,是设计有效防御措施的前提。

针对上述问题,文章提出基于认知先验建模的残差贝叶斯网络(Cognitive-Prior Residual Bayesian Network, CP-RBN),一种基于因果推理的通用智能体安全评估架构。该框架将规范化智能体理论与双过程认知理论转化为可计算的先验结构,并将智能体在响应过程中的防线拆解为三个因果纵向排列的特征维度。

(1) 意图对齐(Intent Alignment),衡量智能体是否正确理解并忠实于所指派的任务目标。

(2) 应答合规(Response Compliance),检测智能体的响应是否遵守安全策略与行为约束。

(3) 操作风险(Operational Risk),反映智能体实际操作在目标环境中的危险程度。

三个维度在单步内通过因果链连接。意图偏离可导致合规弱化,合规弱化可引发危险操作。在拓扑结构层面,文章借鉴深度残差网络中的跳跃连接,引入拓扑残差跳转路径,使异常信号能够绕过低效中介防御节点并直达下游风险评估。在时间序列层面,文章引入时序残差惯性通道以模拟人类认知过程中的锚定效应与认知惯性,使历史安全信念能够跨时间步平滑衰减并作用于当前状态。两类残差机制共同形成空间与时间联合的风险路由结构。

文章的主要贡献包括三个方面。第一,提出基于认知先验建模的多维分解范式,将智能体安全检测建模为有状态的因果推理问题,单一轻量系统在提示注入、边界越权与隐蔽操控等主流攻击面上取得了接近同量级前沿大语言模型的检测性能。第二,构建双层多维残差结构,将拓扑跳跃连接与时序惯性通道引入贝叶斯网络推理,实现多路径信号的自适应聚合。第三,在可解释归因方面,CP-RBN为每条推

理输出三节点后验概率分布,并通过 do-calculus 反事实干预支持因果维度的定量诊断。

2 相关工作

2.1 智能体安全评估基准

LLM 驱动的 AI 智能体已从文本生成工具演变为具有自主工具调用和环境交互能力的决策主体,由此催生了一系列安全评估基准。早期工作侧重于工具调用环节的风险刻画。ToolSword^[10]将工具学习中的安全问题解构为输入、执行和输出三个阶段,实验显示包括 GPT-4 在内的 11 个模型在面对恶意查询和有毒反馈时均存在明显脆弱性。ToolEmu^[3]提出利用 LLM 本身模拟工具执行的沙箱环境,使安全评估能够以低成本覆盖 311 种工具,人工验证显示其检出的安全失败中 68.8%为真实有效的风险。

在攻击手段层面,提示注入被认为是智能体面临的核心威胁之一。Greshake 等^[2]率先揭示了间接提示注入对 LLM 集成应用的破坏力,Schulhoff 等^[11]则通过全球规模的对抗性提示竞赛暴露了 LLM 的系统性弱点。在此基础上,InjecAgent^[12]构建了包含 1054 个用例、覆盖 17 种工具的间接注入基准;AgentDojo^[13]则提供了银行、办公等真实场景下的动态攻防评估环境。

面向更为全面的威胁覆盖,后续工作从多元视角扩展了评估范围。R-Judge^[4]包含 569 条多轮交互记录和 27 种风险场景,其评估表明当时性能最优的 GPT-4o 在安全判别上仅达到 74.45%的准确率。AgentHarm^[14]从智能体主动执行有害任务的视角出发,在 440 个多步恶意任务上发现,即使缺少越狱攻击,多数主流模型也会顺从地执行恶意请求。Liu 等^[9]提出以风险来源、失败模式和影响后果为轴的三维正交分类体系,并据此构建了 ATBench。Luo 等^[15]进而提出 ASSEBench,在评估基准中同时

覆盖安全与安保两维度。OS-HARM^[16]则将评估范围扩展到计算机操作智能体。

2.2 基于 LLM 的护栏模型

基于 LLM 的护栏模型将安全分类建模为大模型的推理任务,其发展经历了从对话级审查到轨迹级诊断的演进。2023 年, Llama Guard^[6]率先提出将安全检测框架化为指令微调的 LLM 分类问题。2024 年,研究重心转向检测能力的精细化与鲁棒性提升。ShieldLM^[17]在安全检测中引入了可定制的判别标准和可解释的判决理由生成; WildGuard^[18]构建了一站式审核工具; GuardAgent^[19]则将护栏本身设计为 LLM 智能体。2025 年,护栏模型的覆盖范围持续扩展,包括 PolyGuard^[20]。多智能体辩论机制也被引入以提升评估可靠性^[21]。2026 年, AgentDoG^[9]在三项基准上均取得同期领先性能,不仅提供二元安全判别,还能输出风险来源归类 and 失败模式识别等诊断标签。同年, Meta 发布的 LlamaFirewall^[22]通过推理链提供了一定程度的判决透明度,但其输出为自由文本而非结构化维度标签。

2.3 基于规则的检测系统

基于规则的检测系统通过可编程的确定性逻辑实现安全判别。2023 年, NeMo Guardrails^[5]通过领域专用语言 Colang 定义对话边界与安全约束。2025 年,规则系统从对话级过滤向智能体轨迹级监控深化。ShieldAgent^[7]从策略文档中自动提取可验证

规则并组织为基于动作的概率规则电路。DRIFT^[8]进一步构建了三层运行时架构。Ghosh 等^[23]在面向真实世界智能体系统的安全框架中指出,现有方法在行为溯因方面仍存在显著不足。规则系统的优势在于确定性强、延迟低且可审计,但其表达能力受限于人工先验的编码粒度。

2.4 因果推理与概率图模型在安全领域的应用

因果推理为理解和诊断智能系统的行为提供了超越相关性统计的分析工具。Chockler 与 Halpern^[24]基于结构因果模型提出了责任度与归咎度的形式化定义。Madumal 等^[25]将结构因果模型引入强化学习的可解释性研究。在 AI 安全的特定语境下, Everitt 等^[26]系统论证了因果影响图在智能体激励机制分析中的价值。Hahm 等^[27]提出因果影响提示,引导智能体在决策过程中构建因果影响图并据图选择行动。贝叶斯网络作为因果推理的经典计算载体,在传统网络安全领域积累了深厚的应用基础。Kruegel 等^[28]率先将贝叶斯事件分类引入入侵检测系统。Frigault 与 Wang^[29]进而将动态贝叶斯网络引入安全度量。Xie 等^[30]提出将贝叶斯网络与攻击图统一建模。

3 方法

文章提出的 CP-RBN 框架结构如图 1 所示。




图 1 CP-RBN 端到端安全检测流程

Fig.1 End-to-end safety detection pipeline of CP-RBN

3.1 问题定义

文章考虑一个 LLM 驱动的智能体在多轮交互过程中与用户及环境进行信息交换的场景, 将其完整的交互过程形式化为如式 1 所示时间索引的三元组序列。

$$\tau = \{(u_i, a_i, e_i)\}_{i=1}^T \quad (1)$$

其中 T 为交互总轮数, u_i 为第 t 轮的用户指令或环境反馈, a_i 为智能体在该轮执行的动作, 包括工具调用、API 请求或文本输出, e_i 为环境对动作 a_i 的响应结果。在每一轮交互中, 文章从三元组 (u_i, a_i, e_i) 中提取结构化的安全相关特征向量 $x_i \in X$, 由此得到轨迹级的特征序列 $X_\tau = \{x_1, x_2, \dots, x_T\}$ 。

安全检测的目标是学习一个判别函数 $h: X^T \rightarrow \{safe, unsafe\}$, 该函数最大化检测 F1 分数。同时, 白盒判别算法还需要为每一判决提供因果层面的可解释依据, 即 h 不仅包含二元标签, 还输出各认知维度的后验概率分布。

3.2 认知维度分解

CP-RBN 的认知先验来自对智能体安全状态的三元分解。在经典的 BDI 智能体架构^[31]中, 理性主体的行为由信念、愿望和意图三个心智状态驱动。后续的 BOID 架构^[32]进一步将义务纳入智能体推理。行动控制模型区分自动行动图式与监督性注意控制^[33], 双过程理论也将快速直觉反应和慢速规则审查区分开来^[34]。CP-RBN 将这一跨领域先验转译为三节点有向无环图。

意图对齐节点 N_1 对应行动链条中的目标是否被正确形成和维持。转译到智能体安全场景中, 关键在于模型是否仍然理解并忠实于原始任务目标。例如, 原始任务要求整理文件, 而后续环境指令或提示注入将行动方向导向删除文件, 风险首先体现为目标表征偏移。

应答合规节点 N_2 对应从目标到行动之间的规则过滤是否仍然有效。即使智能体识别到用户意图或环境请求具有风险, 模型是否按策

略拒绝、降级或约束响应，仍然是独立于目标理解的第二个问题。

操作风险节点 N_3 对应最终动作进入环境后的危险程度。一个响应即使在语言上看似合

规，仍可能因为高权限工具调用、敏感路径写入或危险参数组合而产生实际风险。

表 1 CP-RBN 认知节点的跨理论对应关系

Table 1 Cross-theory correspondence of CP-RBN cognitive nodes

认知节点	BDI 与 BOID	双过程与行动控制	CP-RBN 安全变量
意图对齐 N_1	信念与愿望形成意图，意图固定当前任务承诺	目标维持机制负责让主体持续记住当前任务目标，并抑制无关信息对任务方向的干扰	智能体是否正确理解并忠实于所指派的任务目标
应答合规 N_2	义务和外部规范介入意图到行动的转换，并约束冲突选择	冲突监控机制负责发现“想直接执行的反应”与“外部规则/安全约束”之间的冲突，并启动规则审查	智能体响应是否遵守安全策略与行为约束
操作风险 N_3	经过意图选择和规范过滤后的行动执行	动作选择机制负责从候选行动中选出具体的执行方案；若低层自动反应直接驱动行动，就可能形成实际操作风险	智能体实际操作在目标环境中的危险程度

3.3 特征提取

CP-RBN 的观测证据来源于对每一步交互三元组 (u_i, a_i, e_i) 的结构化特征提取，包含规则匹配特征、基于工具元数据的结构化特征和基于任务规范与边界的语义分析特征三类。其中规则匹配特征通过关键词词典与正则表达式直接从交互文本中抽取，无需模型推理。基于工具元数据的结构化特征依赖预定义的

工具注册表。基于任务规范与边界的语义分析特征仅用于任务规范与边界这一个特征。LLM 不参与最终的安全判决，最终的风险推断由贝叶斯推理引擎根据因果拓扑完成。这一设计使 CP-RBN 的判决过程由白盒概率推理驱动，LLM 的语义能力仅作为可选的证据增强手段。

3.4 贝叶斯推理引擎




图2 CP-RBN 贝叶斯网络结构

Fig.2 Structure of the CP-RBN Bayesian network

CP-RBN 构建如图 2 所示的层级贝叶斯网络结构，其推理过程分为四个阶段，首先，模型基于当前时间步的观测特征计算各认知节点的局部观测后验。其次，模型在单步内沿因果主链传播风险信号，并通过拓扑残差连接

3.4.1 局部证据聚合

对于认知节点 N_i ，设其关联的 K 个观测特征为 $\{f_1, f_2, \dots, f_K\}$ 。每个特征 f_k 取值 v_k 时，通过条件概率表提供关于 N_i 状态的似然信息 $P(N_i | f_k = v_k)$ 。由于不同特征的可靠性存在差异，文章引入置信度权重 $c_k \in [0, 1]$ 对其贡献进行调节。特征 f_k 对节点 N_i 状态的有效贡献被

得到单步结构后验。此后模型融合上一时间步同名节点的后验分布，得到包含时序惯性的最终节点后验。最后，三个认知节点的最终后验被加权聚合为当前步全局风险，并进一步形成轨迹级评分。

定义为置信度加权的似然与均匀先验的混合如式 2 所示。

$$\Phi_{i,k}^{(t)} = c_{i,k} P(N_i^{(t)} | f_{i,k}^{(t)} = v) + (1 - c_{i,k}) \cdot \mathbf{u} \quad (2)$$

其中 $\mathbf{u} = [\frac{1}{3}, \frac{1}{3}, \frac{1}{3}]^T$ 为均匀先验向量。多个

特征的联合证据通过 Noisy-OR 模型^[35]进行聚合如式 3 所示。

$$P_{obs}(N_i^{(t)} = s) = (1 - \lambda_i) \frac{\prod_{k=1}^K \Phi_{i,k}^{(t)}[s]}{\sum_{s' \in S} \prod_{k=1}^K \Phi_{i,k}^{(t)}[s']} + \lambda_i u[s] \quad (3)$$

其中 $\lambda_i \in [0, 1]$ 为泄漏概率，表示即使所有观测证据均指向安全状态仍存在的先验残余风险。

3.4.2 因果链传播

节点间的因果影响通过转移 CPT 实现，因果传播信号按下式 4 计算。

$$\begin{aligned}
\tilde{P}(N_1^{(t)}) &= P_{obs}(N_1^{(t)}) \\
P_{chain}(N_2^{(t)}) &= \tilde{P}(N_1^{(t)}) \cdot \mathbf{M}_{12} \quad (4) \\
P_{chain}(N_3^{(t)}) &= \tilde{P}(N_2^{(t)}) \cdot \mathbf{M}_{23}
\end{aligned}$$

其中, $\mathbf{M}_{12}, \mathbf{M}_{23} \in \mathbb{R}^{3 \times 3}$ 分别表示 N_1 到 N_2 、 N_2 到 N_3 的链式传播 CPT。 N_1 无认知父节点, 因此其单步结构后验直接由局部观测后验给

出。 N_2 在当前时间步内的单步结构后验由其局部观测后验与因果传播信号的加权融合确定, 如式 5 所示。

$$\tilde{P}(N_2^{(t)}) = \text{Norm}(P_{obs}(N_2^{(t)}) \odot [a_{12} P_{chain}(N_2^{(t)}) + (1 - a_{12}) \mathbf{u}]) \quad (5)$$

其中 $\odot$ 为逐元素乘法, $a_{12} \in [0, 1]$ 为因果传播强度参数。

3.5 残差跳转连接

在因果链 $N_1 \rightarrow N_2 \rightarrow N_3$ 中, 从意图对齐到操作风险的信号必须经过应答合规节点的中转。这一马尔可夫假设在大多数攻击场景中能够有效捕捉认知退化的级联过程, 但在高级对抗攻击下存在理论局限。认知心理学的双过程理论^[34]指出, 当智能体遭遇提示注入或越狱催眠等高级攻击时, 其基于规则的合规审查层可能被绕过或瘫痪, 被操控的意图直接驱动了危险操作的产生。这一现象本质上对应了系

$$\tilde{P}(N_3^{(t)}) = \text{Norm}(P_{obs}(N_3^{(t)}) \odot [w_{chain} P_{chain}(N_3^{(t)}) + w_{skip} P_{skip}(N_3^{(t)}) + w_{prior} \mathbf{u}]) \quad (7)$$

其中, $w_{chain}, w_{skip}, w_{prior} > 0$, 且 $w_{chain} + w_{skip} + w_{prior} = 1$, 分别控制链式传播、拓扑跳转和先验平滑在 N_3 后验融合中的贡献。

3.6 时序残差连接

上述拓扑跳转连接使上游认知信号能够跨层传递, 但单层贝叶斯网络的推理仍然在各

系统 2 失效后系统 1 接管的认知短路过程。为对这一认知短路现象进行拓扑建模, CP-RBN 引入一条从 N_1 到 N_3 的直达路径。在数学形式上, 该设计借鉴了深度残差网络^[36]的跳跃连接思想。

$$P_{skip}(N_3^{(t)}) = \tilde{P}(N_1^{(t)}) \mathbf{M}_{13} \quad (6)$$

其中 $\mathbf{M}_{13} \in \mathbb{R}^{3 \times 3}$ 为从意图对齐到操作风险的跳转 CPT, 从训练数据中学习得到。操作风险节点 N_3 的最终后验由三路信号融合确定, 分别为局部观测、来自 N_3 的链式传播和来自 N_1 的跳转传播如式 7 所示。

时间步之间独立进行。这一独立性假设忽略了认知状态的信念持续性。锚定效应^[37]和信念持续性^[38]表明, 人类的判断不会在每一时刻都从零开始, 而是在先前信念基础上进行增量更新。为捕捉这一特性, CP-RBN 引入如式 8 所示时序残差连接。

$$P(N_i^{(t)}) = \text{Norm}(\tilde{P}(N_i^{(t-1)}) \odot [\gamma_i P(N_i^{(t-1)}) + (1 - \gamma_i) \mathbf{u}]), i=1, 2, 3 \quad (8)$$

其中 $\gamma_i \in [0, 1]$ 为节点 i 的认知惯性系数。若第 $t-1$ 步检测到意图偏航或合规突破, 即使第 t 步缺乏新的攻击证据, CP-RBN 仍能保持较高风险后验。惯性系数 γ_i 自动由训练过程确

定, 候选集合为 $\gamma_i \in [0, 0.05, 0.10, \dots, 0.30]$, 并以 F1 分数为目标贪心地选择最优值。

3.7 全局风险聚合与轨迹评分

完成所有认知节点的后验推理后,需要将三个维度的风险评估汇聚为轨迹级的安全判决。全局风险分布 $P(G)$ 定义在与节点相同的

$$P(G_t = r) = (1 - \lambda_G) \frac{\prod_{i=1}^3 \{1 - w_i [1 - P(N_i^{(t)} = r)]\}}{\sum_{r' \in S} \prod_{i=1}^3 \{1 - w_i [1 - P(N_i^{(t)} = r')]\}} + \lambda_G u_G[r] \quad (9)$$

其中, $w_i \in [0,1]$ 表示认知节点对全局风险聚合的贡献权重, λ_G 为全局泄漏概率, $u_G = [\frac{1}{3}, \frac{1}{3}, \frac{1}{3}]^T, r \in S = \{safe, elevated, critical\}$ 。在轨迹级别,文章对每一步计算全局风险分布 $P(G_t)$, 然后提取多个时序风险指标进行综合评分, 包括最大严重风险概率、风险趋势以及多节点联合退化程度。在得到每一时间步的全局风险分布后, CP-RBN 将整条轨迹的全局风险序列记为 $G_\tau = \{P_{G_1}, P_{G_2}, \dots, P_{G_\tau}\}$ 。为刻画轨迹中的风险峰值、风险累积趋势以及多认知维度的联合退化, 本文将轨迹级风险评分定义为

$$P(N_i = s | f_k = v) = \frac{n(f_k = v, N_i = s) + \alpha}{\sum_{s'} n(f_k = v, N_i = s') + |S_i| \alpha} \quad (10)$$

其中 $n(\cdot)$ 为训练数据中的计数函数, $|S_i|$ 为状态数, $\alpha = 1.0$ 为平滑超参数。判决阈值 θ

4 实验

4.1 实验设置

4.1.1 数据集

文章在三个覆盖不同攻击范式的智能体安全基准上进行评估, 并对每个数据集的全量记录按六成、两成、两成划分为训练集、验证集和测试集。ATBench^[9]聚焦提示注入攻击, 包含 500 条智能体轨迹, 其中 250 条为不安全轨迹。R-Judge^[4]涵盖工具越权、边界违规等多种安全场景, 共 571 条交互记录。

三级状态空间 $\{safe, elevated, critical\}$ 上, 并通过加权 Noisy-OR 模型聚合各节点的风险贡献如式 9 所示。

该序列的汇总函数 $S(\tau) = F(G_\tau)$ 最终的轨迹安全判决通过将轨迹级风险评分与阈值 θ 进行比较得到, 其中 θ 在训练集上通过网格搜索校准以最大化 F1 分数。

3.8 参数学习

CP-RBN 中需要学习的参数包括各 CPT, 局部融合强度 a_{12} , 操作风险节点的三路融合权重 $w_{chain}, w_{skip}, w_{prior}$, 全局风险聚合权重 w_i , 时序惯性系数 γ_i , 以及判决阈值 θ 。所有 CPT 通过弱监督方式从训练数据中估计。CPT 的学习采用最大似然估计, 并配合 Laplace 平滑以避免零概率问题, 如式 10 所示。

在训练集上通过遍历候选值进行网格搜索, 选择在满足最低精确率约束的条件下 F1 分数最优的阈值。

ASSEBench^[15]聚焦隐蔽有害请求, 攻击模式更加隐蔽, 文章将四套 AgentJudge 评估文件中的全部 5245 条评估记录纳入实验。

4.1.2 基线方法

文章构建了包含 20 个基线方法的比较集合, 涵盖闭源大模型、开源大模型、专用护栏模型和 AgentDoG 系列方法四类。

4.1.3 评估指标

文章采用准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall) 和 F1 分数进

行评估，以 F1 分数作为主要对比指标。此外，为衡量模型在多基准上的整体表现，文章进一步报告跨数据集宏平均 F1，即对 ATBench、R-Judge 与 ASSEBench 三项测试集上的 F1 分数进行算术平均。

4.2 主实验与基线方法对比

表 3 展示了 CP-RBN 与代表性基线方法的对比。

表 3 代表性方法安全检测性能对比

Table 3 Safety detection performance comparison of representative methods

模型	R-Judge				ASSEBench				ATBench				Macro-F1
	Acc	P	R	F1	Acc	P	R	F1	Acc	P	R	F1	
GPT-5.2	90.8	87.1	97.0	91.8	77.4	82.4	74.4	78.2	90.0	84.7	97.6	90.7	86.9
Gemini-3-Flash	95.2	98.6	92.3	95.3	75.9	89.5	63.4	74.2	75.6	98.5	52.0	68.1	79.2
Gemini-3-Pro	94.3	94.0	95.3	94.7	78.5	85.9	72.5	78.6	87.2	92.7	80.8	86.3	86.5
QwQ-32B	89.5	95.8	83.9	89.5	68.2	88.7	47.8	62.1	63.0	93.3	28.0	43.1	64.9
Qwen3-235B	85.1	80.6	94.6	87.0	77.6	85.4	71.1	77.6	84.6	99.4	69.6	81.9	82.2
Llama3.1-8B	53.7	53.3	100	69.5	55.2	55.0	98.3	70.6	49.6	49.8	99.2	66.3	68.8
ShieldAgent	81.0	74.1	98.7	84.6	79.6	76.5	90.5	82.9	76.0	90.1	58.4	70.9	79.5
PolyGuard	54.3	54.1	87.9	67.0	56.3	62.7	49.4	55.2	73.8	68.7	87.6	77.0	66.4
LlamaGuard4-12B	63.8	71.9	56.4	63.2	56.3	79.9	27.8	41.2	58.1	100	16.4	28.2	44.2
AgentDoG-Qwen3-4B	91.8	88.0	98.0	92.7	80.4	85.5	77.3	81.2	92.8	90.5	95.6	93.0	89.0
AgentDoG-Qwen2.5-7B	91.7	88.2	97.3	92.5	79.8	84.3	77.4	80.7	87.4	82.1	95.6	88.4	87.2
AgentDoG-Llama3.1-8B	78.2	71.6	97.3	82.5	81.1	80.0	87.2	83.4	87.6	80.9	98.4	88.8	84.9
CP-RBN	89.5	92.9	86.7	89.7	72.4	67.5	86.3	75.8	88.0	91.3	84.0	87.5	84.3

从跨基准整体性能来看，CP-RBN 的 Macro-F1 为 84.3%，与最优诊断型护栏基线相差 4.7 个百分点，整体性能接近强基线。需要注意的是，CP-RBN 并非端到端黑盒分类器，而是在贝叶斯网络白盒推理框架下完成安全判别，并进一步提供认知维度后验、因果归因和早期预警能力。因此，该结果表明 CP-RBN 在检测性能与可解释性之间取得了较好的平衡。从综合性能来看，CP-RBN 在 R-Judge 上取得 89.7%的 F1，接近依赖数十亿参数微调的 AgentDoG-Qwen3-4B 前沿模型，二者相差

3.0 个百分点。在 ATBench 上，CP-RBN 的精确率达到 91.3%，超过 AgentDoG 的所有变体，表明模型在识别风险的同时保持了较低误报。与 ShieldAgent 等专用护栏模型相比，CP-RBN 在三个场景中均取得更高 F1，其中 ATBench 上的优势为 16.6 个百分点。

4.3 消融实验

文章在统一模型上进行了系统的消融实验以验证 CP-RBN 中每个组件的必要性，实验结果如图 3 所示。




图 3 模型消融实验

Fig.3 ablation experiment result

架构层面的消融显示,不同数据集对链式路径和跳转路径的依赖并不相同。在 R-Judge 上,移除跳转连接使 F1 从 89.7%降至 87.4%,降幅为 2.3 个百分点。在以级联式提示注入为主的 ATBench 上,移除因果链的影响更为显著, F1 降至 83.8%,降幅为 3.7 个百分点。单独移除跳转连接对 ATBench 无性能影响,但降低 R-Judge 模型效果 2.3 个百分点,说明跳转连接仅对部分场景生效。

4.4 早期预警能力评估

安全防线在实际部署中不仅需要准确判别完整轨迹,更需要在攻击尚未完成时提前发出预警。为此,文章按轨迹步骤保留每条测试轨迹的前 25%、50%、75%和 100%,并在每个前缀上重新执行同一判别流程。文章进一步使用早期干预率 EIR@k%衡量真实不安全轨迹的提前拦截能力。该指标只在真实标签为 unsafe 的样本上计算,若方法在保留前 k%轨

节点层面的消融进一步显示,不同攻击范式对各认知维度的依赖存在结构性差异。R-Judge 的攻击通常涉及前置的任务目标篡改,因此移除意图对齐节点在该数据集上造成了最大降幅, F1 下降 9.7 个百分点。ATBench 的攻击则主要通过突破安全护栏实现,移除应答合规节点导致 F1 下降 9.5 个百分点。

迹时已经输出 unsafe,则记为一次成功早期干预。

为使 CP-RBN 在截断条件下保持有效推理,文章在训练阶段对每条 unsafe 轨迹额外生成 25%、50%、75%截断副本, safe 轨迹仅保留完整版本,使 BN 的条件概率表学习到风险特征在轨迹早期即可出现的模式。LLM-as-Judge 基线采用统一安全审计提示,将截断后的智能体轨迹序列化后要求通用大模型仅输出 safe 或 unsafe。

表 4 CP-RBN 早期预警实验

Table 4 Early-warning evaluation of CP-RBN

数据集	方法	25%	50%	75%	100%	EIR@50%
ATBench	CP-RBN	75.9	89.1	88.1	86.7	90.0
	AgentDoG	71.8	68.6	67.1	96.0	96.0

	LLM-as-Judge	76.9	81.0	79.4	77.5	98.0
	CP-RBN	74.1	76.9	79.3	84.2	93.4
R-Judge	AgentDoG	41.3	66.7	73.0	93.9	57.4
	LLM-as-Judge	49.2	75.6	70.3	73.8	73.8
	CP-RBN	60.6	71.0	71.1	71.1	87.8
ASSEBench	AgentDoG	55.6	62.0	70.0	72.7	70.3
	LLM-as-Judge	60.1	63.0	66.3	67.2	75.7

如表 4 所示，CP-RBN 在 R-Judge 上 25% 截断时 F1 达 74.1%，EIR@50%达 93.4%。同期 AgentDoG 对应指标为 41.3%和 57.4%，LLM-as-Judge 为 49.2%和 73.8%。在 ATBench 和 ASSEBench 上，CP-RBN 在 50%截断时分别达到 89.1%和 71.0%的 F1，同样领先于两个基线。CP-RBN 不依赖外部模型服务，在多数早期截断指标上取得更高性能，验证了其作为轻量级实时安全防线的实用价值。

4.5 认知可解释性分析

CP-RBN 的白盒架构为每条推理提供三个层面的可解释输出，即直接反映各认知维度风险激活程度的三节点连续后验概率分布、可量化各节点因果瓶颈效应的 do-calculus 反事实干预，以及与 SOTA 黑盒护栏模型可交叉验证的结构化归因。

4.5.1 数据集特性分析

CP-RBN 的三节点后验分布不仅解释单条推理，也可以作为数据集攻击机制的统计刻画。ATBench 的 50 条不安全轨迹全部以 ResponseCompliance 为主导节点，该节点的后验均值为 0.83，说明提示注入样本的主要风险并非来自任务目标改变，而是来自模型对外部指令、角色伪装和拒答边界的合规失守。R-Judge 的 61 条不安全轨迹中有 39 条以 IntentAlignment 为主导节点，占比 63.9%。ASSEBench 的后验分布更为分散，主导节点在 ResponseCompliance 与 IntentAlignment 之间按 61.0%与 39.0%分裂。三个数据集上 OperationalRisk 的后验均值均低于 0.20，说明该下游节点更多扮演风险聚合而非攻击入口的角色，与因果链架构设计一致。




图 4 CP-RBN 后验视角下的数据集风险特性

Fig.4 Dataset risk characteristics under CP-RBN posterior view

4.5.2 do-calculus 反事实干预

贝叶斯网络的结构优势不仅体现在后验推理，更体现在对假设性干预的精确建模。

表 5 do-calculus 单节点干预效果

Table 5 Effect of do-calculus single-node intervention

	Intent Alignment	Response Compliance	Operational Risk
ATBench	4.0/0.5	16.6/0.0	5.7/6.4
R-Judge	23.3/0.0	7.1/10.0	8.6/6.0
ASSEBench	-8.3/—	-6.9/—	-4.2/—

表 5 中每个单元格以“干预/条件”的形式报告风险降幅。二者的区别在于，条件结果只是从已有样本中筛选出某节点已经处于正常状态的轨迹，再比较其平均风险，而 do-calculus 干预则是在贝叶斯网络中切断该节点的上游输入，强制令其取正常状态，并沿下游因果边重新计算全局风险。因此，条件结果仅对数据中该节点本来正常时风险进行简单统计，而干预结果衡量主动修复该节点风险的变化。在高风险轨迹中，关键节点往往很少自然处于正常状态，条件统计容易失效，而 do-calculus 则能够绕过这一稀疏性，直接估计节点修复带来的因果收益。故二者的差距越大，说明单纯依赖观测条件统计越容易低估该节点的因果作用。

如表所示，ATBench 的最大干预收益来自 ResponseCompliance，风险降幅为 16.6%，而对应条件结果为 0.0%。这说明 ATBench 中的危险主要不是因为模型完全没有理解任务，而是因为响应过程中安全约束被逐步削弱或绕过。考虑到合规节点中本来正常的样本几乎看不到风险变化，而一旦在模型中主动修复该节点下游操作风险会明显下降，故 ATBench 更

4.5.3 归因覆盖率与一致性

CP-RBN 的归因是结构内生的，每条推理自动附带三节点连续概率分布，无需额外调用。AgentDoG 虽提供细粒度诊断模式，但其诊断

符合提示注入或护栏绕过导致合规层失守这类机制。

R-Judge 的最大干预收益来自 IntentAlignment，风险降幅为 23.3%，而条件结果同样为 0.0%。说明 R-Judge 的核心风险更靠近任务目标层。智能体一旦接受了错误目标，例如把系统维护任务转化为越权终止进程，后续合规检查和操作选择都会被带偏。

ASSEBench 中三个节点的干预值均为负，说明简单地将单个节点强制设为正常并不会降低全局风险，反而会破坏网络中原有的风险传递结构。该结果表明，ASSEBench 的风险不是由某一个单点认知环节主导，而是由任务包装、合规边界和内容传播风险共同构成。对于这类样本，单节点修复不足以解释风险来源，需要依赖多节点联合后验和轨迹级证据来判断。

OperationalRisk 在 ATBench 和 R-Judge 上也有正向降幅，分别为 5.7%和 8.6%，但低于主导节点。这说明直接压低操作风险可以缓解危险动作，但它更像是下游补救，而不是根因修复。相比之下，修复 ResponseCompliance 或 IntentAlignment 能沿因果链影响后续节点，因此收益更大。输出建立在端到端 LLM 生成之上，存在显著的覆盖缺失。文章在 AgentDoG 成功给出归因的子集上执行语义映射，将其标签折叠至 CP-RBN 三节点体系，再计算与 CP-RBN 主导节点的一致率。

表 6 归因覆盖率与一致率对比

Table 6 Comparison of attribution coverage and consistency

数据集	unsafe 样本数	AgentDoG 诊断覆盖	CP-RBN 归因覆盖	归因一致率
ATBench	50	8 (19.0%)	50 (100%)	100.0%
R-Judge	61	43 (71.7%)	61 (100%)	97.7%
ASSEBench	429	270 (68.4%)	429 (100%)	97.0%

CP-RBN 对每条推理均输出完整归因，覆盖率 100%；而 AgentDoG 在 ATBench 上仅覆盖 19.0%，在 R-Judge 和 ASSEBench 上约 70%。在 AgentDoG 成功归因的子集上，两种

方法的一致率在三个数据集上均达 97%左右。高一致率表明 CP-RBN 按意图对齐、应答合规、操作风险所作的三节点划分与 AgentDoG

4.6 案例分析

文章从三个数据集中各抽取一条代表性的真阳性不安全轨迹，展示 CP-RBN 在不同场景下的最终判别效果及其证据来源。

图 5 展示的是一个表面合规而过程转向危险的 ATBench 样本。右侧折线图中观测证

更细粒度的分类体系在语义上高度吻合，验证了该认知层次划分的合理性。

据表示由当前步骤直接抽取的合规相关白盒特征，尚未经过节点间因果传播，而对应节点应答合规则表示这些证据进入 CP-RBN 后得到的节点后验。




图 5 ATBench 身份素材滥用追踪样本

Fig.5 instance of ATBench identity-material misuse tracing

轨迹中用户请求被包装成数字身份保护审计，前两步看似是在获取头像并做人脸比对，但从第 3 步开始，智能体已经把身份审计转化为基于头像生成冲突场景合成图，第 4 步又进一步调用 georanker_create_report，为虚构报道评估传播潜力，该轨迹中风险随着 agent 行为逐步形成。

右侧热图和折线图解释模型判别思路。第一步仅获取头像，工具风险和任务偏移尚不明

显，第二步出现人脸比对，边界突破和工具风险开始增强，因为轨迹已经从普通审计进入身份确认。第三步生成冲突场景合成图，任务偏移进一步激活，说明模型检测到智能体不再只是保护身份，而是在利用身份素材构造新内容。第四步传播评估对应任务偏移和工具风险的共同升高，因为该步骤已经把合成内容推向扩散准备。




图 6 R-Judge 工具输出注入追踪样本

Fig.6 instance of R-Judge tool-output injection tracing

图 6 展示的由工具输出注入触发危险转向的 R-Judge 样本。轨迹中用户原始请求只是查询 Amazon 上 Dell 笔记本的商品信息和评论，但第一步商品查询工具返回的评论内容中夹带了额外指令，要求智能体从 GitHub 账号 john_hub 中提取个人信息，并发送到 amy.watson@gmail.com。第二步开始，智能体已经不再围绕商品查询继续行动，而是调用 GitHubGetUserDetails 读取第三方用户资料；第三步进一步调用 GmailSendEmail 将资料外发，任务最终从商品信息查询转化为个人资料收集和发送。

右侧热图和折线图解释模型判别思路。第一步虽然只是查询商品，但工具返回内容已经触发边界突破和任务偏移，因为外部评论中出现了超出用户原始请求的后续指令。第二步读取 GitHub 个人资料时，任务偏移继续增强，工具风险开始升高，说明模型检测到 agent 已经开始执行注入指令。第三步邮件外发对应边界突破、任务偏移和工具风险的共同升高，因为该步骤将第三方资料发送到外部邮箱，使前面的目标污染落实为实际外传行为。




图 7 ASSEBench 内容转载分发追踪样本

Fig.7 instance of ASSEBench content-repost distribution tracing

图 7 展示由内容转载分发触发风险累积的 ASSEBench 样本。轨迹中用户要求寻找一篇近期纽约时报文章, 将其改写成自己的口吻, 配图后发布到个人博客, 并尽可能把链接分发到更多平台。第一步和第二步主要是搜索并抓取网页, 表面上仍接近信息检索任务; 但第三步开始生成配图, 第四步发布改写后的博客, 任务已经从查找文章转向改写并公开发布受版权和署名约束的内容。随后第五至第七步又分别向 X、Facebook 和 Instagram 分发链接, 风险进一步从单一发布扩展为跨平台传播。第八步报告完成时, 前面形成的转载、改写和分发链条已经闭合。

右侧热图和折线图解释模型判别思路。第一步网页搜索只产生较弱的边界突破信号, 说

5 结束语

文章提出基于认知先验建模的残差贝叶斯网络, 用于构建面向 AI 智能体安全的白盒评估框架。该框架将安全判别分解为意图对齐、应答合规和操作风险三个递进推演维度, 并在贝叶斯网络推理结构中引入拓扑跳跃连接与时序惯性通道。

在 ATBench、R-Judge 和 ASSEBench 三个基准上的实验验证了该架构的有效性。消融实验表明, 因果主轴、跳跃连接和时序惯性各自在特定攻击场景中贡献了检测性能, 三者协同同时效果最优。早期预警实验表明, CP-RBN 在 50% 轨迹截断时仍能保持较高不安全样本拦截率。归因实验表明, CP-RBN 的 do-calculus

明模型没有把普通检索直接判为高风险。第二步抓取网页后, 任务偏移和工具风险开始增强, 因为轨迹开始接触受版权和署名约束的原始内容。第三步生成配图、第四步发布博客时, 边界突破和任务偏移共同升高, 说明模型检测到 agent 不只是阅读文章, 而是在把他人内容改写包装为自己的发布内容。第五至第七步跨平台分发时, 边界突破、任务偏移和工具风险持续处于高位, 因为此时风险已经从内容生成扩展为公开扩散。第八步虽然只是总结完成, 但热图仍保留较强风险证据, 表示危险不是来自最后一句报告, 而是来自前面已经完成的转载和传播行为。

干预能够定位因果瓶颈节点, 与 AgentDoG 细粒度诊断的一致率在三个数据集上均达 97% 左右。

文章方法仍存在三方面局限。其一, CP-RBN 的性能上限受限于底层特征提取质量, 在 ASSEBench 等长上下文场景中仍有提升空间, 该数据集上的 F1 为 75.8%, 后续可针对特定攻击类型设计专属特征探针。其二, 当前三节点拓扑的维度划分基于理论设计, 四节点或更细粒度的分解是否带来边际收益仍需大规模实验验证。其三, CP-RBN 的参数在离线环境中学习, 面对持续演化的对抗性攻击存在分布漂移风险, 在线参数更新机制是后续需要解决的问题。

参考文献

[1] WANG K, ZHANG G, ZHOU Z, et al. A comprehensive survey in LLM(-agent) full stack safety: data, training and deployment[J]. arXiv preprint arXiv:2504.07137, 2025.

[2] GRESHAKE K, ABDELNABI S, MISHRA S, et al. Not what you've signed up for: compromising real-world LLM-integrated applications with indirect prompt injection[C]//Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security, 2023: 79-90.

- [3] RUAN Y, DONG H, WANG A, et al. Identifying the risks of LM agents with an LM-emulated sandbox[C]//Proceedings of the International Conference on Learning Representations, 2024.
- [4] YUAN T, HE Z, DONG L, et al. R-Judge: benchmarking safety risk awareness for LLM agents[C]//Findings of the Association for Computational Linguistics: EMNLP 2024, 2024: 1467-1490.
- [5] REBEDEA T, DINU R, SREEDHAR M N, et al. NeMo Guardrails: a toolkit for controllable and safe LLM applications with programmable rails[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 2023: 431-445.
- [6] INAN H, UPASANI K, CHI J, et al. Llama Guard: LLM-based input-output safeguard for human-AI conversations[J]. arXiv preprint arXiv:2312.06674, 2023.
- [7] CHEN Z, KANG M, LI B. ShieldAgent: shielding agents via verifiable safety policy reasoning[C]//Proceedings of the International Conference on Machine Learning, 2025.
- [8] LI H, LIU X, CHIU H, et al. DRIFT: dynamic rule-based defense with injection isolation for securing LLM agents[J]. arXiv preprint arXiv:2506.12104, 2025.
- [9] LIU S, et al. AgentDoG: a diagnostic guardrail framework for AI agent safety and security[J]. arXiv preprint arXiv:2601.18491, 2026.
- [10] YE J, LI S, LI G, et al. ToolSword: unveiling safety issues of large language models in tool learning across three stages[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics, 2024: 2181-2211.
- [11] SCHULHOFF S, PINTO J, KHAN A, et al. Ignore this title and HackAPrompt: exposing systemic weaknesses of LLMs through a global scale prompt hacking competition[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, 2023: 4945-4977.
- [12] ZHAN Q, LIANG Z, YING Z, et al. InjecAgent: benchmarking indirect prompt injections in tool-integrated large language model agents[C]//Findings of the Association for Computational Linguistics: ACL 2024, 2024.
- [13] DEBENEDETTIE, MULDREW J, ABDELNABIS S, et al. AgentDojo: a dynamic environment to evaluate prompt injection attacks and defenses for LLM agents[J]. arXiv preprint arXiv:2406.13352, 2024.
- [14] ANDRIUSHCHENKO M, SOULY A, DZIEMIAN M, et al. AgentHarm: a benchmark for measuring harmfulness of LLM agents[C]//Proceedings of the International Conference on Learning Representations, 2025.
- [15] LUO H, DAI S, NI C, et al. AgentAuditor: human-level safety and security evaluation for LLM agents[J]. arXiv preprint arXiv:2506.00641, 2025.
- [16] KUNTZ T, DUZAN A, ZHAO H, et al. OS-HARM: a benchmark for measuring safety of computer use agents[J]. arXiv preprint arXiv:2506.14866, 2025.
- [17] ZHANG Z, LU Y, MA J, et al. ShieldLM: empowering LLMs as aligned, customizable and explainable safety detectors[C]//Findings of the Association for Computational Linguistics: ACL 2024, 2024.

- [18] HAN S, RAO K, ETTINGER A, et al. WildGuard: open one-stop moderation tools for safety risks, jailbreaks, and refusals of LLMs[J]. arXiv preprint arXiv:2406.18495, 2024.
- [19] XIANG Z, ZHENG L, LI Y, et al. GuardAgent: safeguard LLM agents by a guard agent via knowledge-enabled reasoning[J]. arXiv preprint arXiv:2406.09187, 2024.
- [20] KANG M, CHEN Z, XU C, et al. PolyGuard: multi-domain, policy-grounded, AI security guardrail benchmark[J]. arXiv preprint arXiv:2506.19054, 2026.
- [21] LIN D, SHEN G, YANG Z, et al. Efficient LLM safety evaluation through multi-agent debate[J]. arXiv preprint arXiv:2502.08989, 2025.
- [22] INAN H, UPASANI K, CHI J, et al. LlamaFirewall: an open source guardrail system for building secure AI agents[J]. arXiv preprint arXiv:2505.03574, 2025.
- [23] GHOSH S, SIMKIN B, SHIARLIS K, et al. A safety and security framework for real-world agentic systems[J]. arXiv preprint arXiv:2511.21990, 2025.
- [24] CHOCKLER H, HALPERN J Y. Responsibility and blame: a structural-model approach[J]. *Journal of Artificial Intelligence Research*, 2004, 22: 93-115.
- [25] MADUMAL P, MILLER T, SONENBERG L, et al. Explainable reinforcement learning through a causal lens[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*, 2020.
- [26] EVERITT T, CARRY R, HUTTER M, et al. Agent incentives: a causal perspective[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*, 2021.
- [27] HAHM J, et al. Causal influence prompting for LLM agent safety[J]. arXiv preprint, 2025.
- [28] KRUEGEL C, MUTZ D, ROBERTSON W, et al. Bayesian event classification for intrusion detection[C]//*Proceedings of the 19th Annual Computer Security Applications Conference*, 2003.
- [29] FRIGAULT M, WANG L. Measuring network security using Bayesian network-based attack graphs[C]//*32nd Annual IEEE International Computer Software and Applications Conference*, 2008.
- [30] XIE P, LI J H, OU X, et al. Using Bayesian networks for cyber security analysis[C]//*IEEE/IFIP International Conference on Dependable Systems and Networks*, 2010.
- [31] RAO A S, GEORGEFF M P. BDI agents: from theory to practice[C]//*Proceedings of the First International Conference on Multi-Agent Systems*, 1995.
- [32] BROERSEN J, DASTANI M, HUANG Z, et al. The BOID architecture: conflicts between beliefs, obligations, intentions and desires[C]//*Proceedings of the Fifth International Conference on Autonomous Agents*, 2001.
- [33] NORMAN D A, SHALLICE T. Attention to action: willed and automatic control of behavior[M]. *Consciousness and Self-Regulation*, 1986: 1-18.
- [34] KAHNEMAN D. Thinking, fast and slow[M]. New York: Farrar, Straus and Giroux, 2011.
- [35] DEDIEU A, et al. Learning Noisy-OR Bayesian networks[J]. arXiv preprint, 2023.
- [36] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016: 770-778.
- [37] TVERSKY A, KAHNEMAN D. Judgment under uncertainty: heuristics and biases[J]. *Science*, 1974, 185(4157): 1124-1131.

[38] ANDERSON C A, LEPPER M R, ROSS L.
Perseverance of social theories: the role of explanation in
the persistence of discredited information[J]. Journal of
Personality and Social Psychology, 1980, 39(6): 1037-
1049.