

面向情报文本的多智能体无监督事件骨架生成方法

李明锋¹ 李欣^{1,2} 王军杰¹ 马翼腾¹ 李满^{1,2}

(1. 中国人民公安大学信息网络安全学院 北京 100038;

2. 安全防范技术与风险评估公安部重点实验室 北京 100038)

摘要:[目的]为解决现有监督式事件骨架生成方法依赖大量高质量标注数据、在数据稀缺的低资源场景下难以高效构建事件骨架的问题,本文探讨多智能体驱动的事件骨架生成路径,为该场景下的相关任务提供方法参考。[方法]本文提出了一种基于多智能体协作的无监督事件骨架生成框架 MAU-GES,通过设计基于多智能体的图抽取算法和基于语义的意义段拆分算法,实现了从原始文本到事件骨架图的端到端生成,且无需训练数据。[结果/结论]实验结果表明,所提出的方法在简易爆炸装置数据集上各项评价指标相比前人研究平均提升 1.5% 到 18.8%。消融实验进一步验证了 MAU-GES 中各部分多智能体的有效性,框架相比基准方法在事件覆盖度和准确性方面均有显著提升。

关键词:事件骨架;大语言模型;智能体;无监督学习;情报文本;自然语言处理

中图分类号:TP319

Unsupervised Event Skeleton Generation Method for Multi-Agent-Driven Intelligence Text

Li Mingfeng¹ Li Xin^{1,2} Wang Junjie¹ Ma Yiteng¹ Li Man^{1,2}

(1. People's Public Security University of China, Beijing 100038;

2. Key Laboratory of Security Technology and Risk Assessment, Ministry of Public Security, Beijing 100038)

Abstract: [Purpose] In order to solve the problem that the existing supervised event skeleton generation methods rely on a large number of high-quality labeled data, and it is difficult to efficiently build event skeletons in low-resource scenes with scarce data, this paper discusses the multi-agent-driven event skeleton generation path, which provides method reference for related tasks in this scene. [Method] This paper proposes an unsupervised event skeleton generation framework, named MAU-GES, which is based on large language model (LLM)-driven multi-agent collaboration. Requiring no training data, this framework achieves end-to-end generation from raw text to event skeleton graphs by designing a multi-agent-based graph extraction algorithm. [Result/Conclusion] Experimental results demonstrate that the proposed method exhibits an average improvement of 1.5% to 18.8% across all evaluation metrics on the Improvised Explosive Device (IED) dataset compared with prior studies. Furthermore, ablation experiments further validate the effectiveness of the various multi-agent components in MAU-GES, and the framework achieves significant improvements in both event coverage and accuracy compared with baseline methods.

Key words: event skeleton; Large language models; agents; unsupervised learning; intelligence text; natural language processing

0 引言

随着信息化进程深度推进,互联网场景下涌现出海量与突发事件相关的非结构化情报文本。对这类文本进行高效采集与深度分析,已成为支撑相关部门开展风险预警的核心基础,具有重要的现实应用价值。事件骨架生成作为解析事件演化规律的关键技术环节,其核心功能在于从非结构化文本中自动提取事件类型,并构建事件间的时序关联关系,为后续事件分析提供结构化语义支撑。

当前主流事件骨架生成算法普遍采用两步式路径,首先依托由多种自然语言处理(Natural Language Processing, NLP)模型组合而成的信息提取系统(Information Extraction System, IE)从非结构化文本中解析出各个事件的事件图,再以这些事件图作为训练数据,通过有监督学习算法拟合生成统一的事件骨架图。然而,在突发事件文本样本量不足的低资源场景下,缺乏足量高质量的标注训练数据使有监督学习方法生成效果受限,难以构建高质量事件骨架。

近年来,大语言模型(Large Language Models, LLMs)的快速发展为NLP带来创新进展,基于LLMs的NLP模型仅用少样本提示就可达到良好识别效果^[27]。其核心原因在于,LLMs通过海量文本预训练已具备通用语言建模能力,同时其良好的领域迁移能力可使其快速适配各类下游任务^[28]。基于此,将LLMs引入事件骨架生成领域,有望突破传统方法对标注数据与信息提取工具的依赖,构建无需大规模训练数据的事件骨架生成算法,实现从非结构化文本到重点事件骨架端到端构建,提升对突发事件的响应效率。

1 文献综述

1.1 事件骨架生成

事件骨架生成的核心目标是从特定类型事件的大规模情报文本语料中,归纳并构建该类事件的标准化发展流程图。在该领域研究初期,学者们主要依托统计学方法与机器学习技术,探索从非结构化文本中提取事件链或事件流程的技术路径。Chambers等^[2]于2008年率先提出“事件链”概念,并基于统计学方法与凝聚聚类算法,设计首个从文本中无监督提取事件链的模型;美军研究实验室^[3]于2016年提出自由事件提取(Liberal Event Extraction)算法,实现了对文本中事件流程的有效提取。

随着深度学习技术在自然语言处理领域的快速发展,事件骨架的提取对象逐步从单一元事件或事件链,演进为能够刻画事件演化规律的事件骨架图谱。Wen

等^[1]于2021年研发了Resin信息提取系统,支持从多语言多模态材料中提取事件信息,并实现了事件图谱的自动化构建功能。Li等^[4]于2022年以OneIE信息提取工具^[5]为基础,构建了简易爆炸装置(Improvised Explosive Device, IED)专用数据集,并结合图神经网络与XLNet模型,同时实现了事件骨架图谱的提取与未来事件的预测任务。Zhu等^[6]于2023年首次将扩散模型引入事件骨架图谱构建任务。Hao等^[7]于同年在扩散模型的技术框架下引入大语言模型,实现了事件骨架图谱结构的自动扩充;IBM于2024年提出CHRONOS系统^[8],通过多类型文本蕴含语料库MultiNLI对RoBERTa-Large模型进行微调,实现对新闻文本中事件骨架图谱的提取。

1.2 大语言模型与自然语言处理

近年来,LLMs依托海量预训练数据所习得的语言建模能力,在命名实体识别(Named Entity Recognition, NER)^[10]、共指消解(Coreference Resolution, CR)^[15-16]等NLP核心任务中展现出优异性能。

例如,在NER领域,相关研究已从传统机器学习方法及早期深度学习模型逐步演进至以LLMs为核心的技术范式^[10]。Wang等人^[11]系统探讨了LLMs融入NER任务的机遇与挑战,重点剖析了上下文学习与微调两类关键技术路径。Yang等人通过指令微调将NER任务转化为更适配LLM的生成式任务^[12]。Li等人借助LLM生成外部知识以强化模型对实体的语义理解^[13]。Wu等人通过因果表示学习缓解LLM在跨领域NER任务中存在的实体偏差问题^[14]。在CR领域,Li等人^[17]提出的BoostER系统,借助GPT-4实现智能提问与验证,最终达成低成本、易部署的高质量实体解析效果。

值得注意的是,LLMs具备优异的迁移学习与少样本学习能力,这使其在低资源与多语言场景中展现出独特应用优势。Balluff等人^[18]对多类多语言NER工具的性能展开评估,结果表明,基于Transformer架构的LLMs(如XLM-RoBERTa)在多数语言场景下的性能优于传统模型,且对含噪声数据具备较强鲁棒性;Theptakob等人^[19]针对泰语这类低资源语言,提出以微调后的Longformer模型作为编码器的跨文档共指消解方法,为其他低资源语言的共指消解模型构建提供了有效技术框架。

1.3 基于大语言模型的多智能体系统

当前,LLMs逐渐成为多智能体系统(Multi-Agent System, MAS)的核心载体,为下游任务提供更优语言建模支撑^[22]。这一趋势来自于MAS处理复杂的多步骤任务的能力,以及LLMs对多模态输入的理解和建模能力^[23]。基于这一特性,基于LLMs的MAS系统

被应用在多个领域。自然语言处理领域, Li 等人^[20]通过构建基于多智能体通信模块的嵌套 NER 模型, 显著提升了 NER 任务的边界检测精度。科研模拟和软件开发领域, Swanson 等人^[24]构建多智能体, 辅助人类进行科学研究。Qian 等人^[25]设计多智能体协作模块 ChatDev 进行软件开发。Fourney 等人^[26]开发 Magentic-One 多智能体协作框架, 可泛化解决多种领域的复杂问题。上述基于 LLMs 的 MAS 框架在各自领域展现出了优良性能, 且对领域训练数据和资源要求较低, 在低资源情境下也能展现出良好应用水平。

综上, 当前事件骨架生成方法仍存在以下不足。算法层面, 现有模型多基于骨架图谱的图结构特性设计, 导致模型需依赖 IE 才可实现从文本到骨架图谱的端到端生成; 在应用层面, 现有算法以有监督学习为主, 需获取大量带标注的图谱数据作为训练样本, 在低资源环境下难以展现出理想性能。

针对上述问题, 本文提出多智能体驱动的无监督情报文本事件骨架生成框架 (Multi-Agent Unsupervised Model for Generating Event Schema, MAU-GES)。MAU-GES 以非结构化情报文本为输入, 以事件骨架生成的全流程任务逻辑为核心, 将 workflow 拆解为事件提取和图谱构建两类子任务。本研究的主要贡献归纳如下:

(1) 提出基于多智能体协作的情报文本事件骨架提取框架 MAU-GES。该框架突破单一模型处理长文本时的上下文过载局限和有监督学习算法对大量标注数据需求的局限, 为低资源场景下的事件骨架生成提供新的技术路径。

(2) 设计基于语义的意义段拆分算法。针对低资源场景中不常见事件流程提取精度不足的缺陷, 算法通过语义单元拆分实现对文本细节的精细化挖掘, 避免单一模型因全局语义稀释导致的特殊环节遗漏。

(3) MAU-GES 框架在仅用不到 50% 的全量数据的条件下, 在事件骨架事件提取指标 $F1_{EM}$ 和事件链提取指标 $F1_{ESM}$ 上相比前人研究平均提升 1.5% 到 18.8%。

(4) 通过设计多组差异化 LLMs 配置方案, 系统探究了不同能力维度的 LLMs 在框架各子任务中的适配模式, 为框架在效率与精度间实现最优平衡提供了

量化实验支撑。

2 研究方法

2.1 整体框架

针对低资源场景, MAU-GES 以 LLMs 为核心驱动, 构建多智能体协作框架。框架结构方面, 考虑到事件骨架提取 workflow 中各多智能体工作任务较为固定, MAU-GES 采用文献^[23]中提出的分层结构构建多智能体。为解决当前研究中信息提取与事件骨架图构建流程割裂的核心问题, 框架设计事件提取类与图谱构建两大核心模块, 通过分层机制实现二者动态聚合与流程衔接, 消除传统方法因流程脱节导致的语义断层。框架示意如图 1 所示。




图1 MAU-GES 整体框架图

2.2 事件提取多智能体

针对情报文本的事件骨架生成任务, MAU-GES 框架构建了语义感知型多智能体协作网络, 通过三类功能智能体的分层协同, 实现非结构化文本到事件要素的精准抽取。在大语言模型语境下, 单个智能体采用提示工程构建。对于输入语料 C , 定义嵌入语料的提示工程文本为 $P(C)$ 。事件提取多智能体内部协作示意

图如图 2 所示。




图 2 事件提取多智能体内部协作图

2.2.1 多文档事件链完整性评估智体

多文档事件链完整性评估智体 (Multi-Document Event Chain Integrity Evaluation Agent, MDE-EA) 的核心目标是从海量情报文本中筛选高价值语料,降低后续处理冗余度。在初提取阶段,MDE-EA 接受预设

的文档数 N_{doc} 作为筛选阈值,调用 LLMs 对输入情报文本进行事件链初提取,输出该文本对应的初步事件链,并以事件链包含的事件动作单元数量作为完整性量化指标。在文本筛选阶段,智体采用贪心算法对所有文本的事件链长度进行排序,选择文本事件链长度排名前 N_{doc} 的文本作为后续处理语料。

2.2.2 文本分割智体

文本分割智体 (Text Segmentation Agent, TSA) 采用基于 LLMs 的意义段拆分优化算法,核心功能是将 MDE-EA 筛选后的长文本按语义完整性拆分为短文本段 $T = \{T_1, T_2, \dots, T_n\}$ 。智体保证每个分段仅围绕一个核心事件场景展开,避免跨场景语义混杂。另外智体还保障每个分段包含事件动作的核心动词,确保后续智体提取的事件动作单元具备语义完整性。对于非中文文本, TSA 优先将文本翻译成中文,再基于中文进行意义段拆分。TSA 对爆炸袭击情报长文本拆解样例如表 1 所示。

表 1 情报长文本拆解样例

原文	传统分词结果	意义段拆分结果	核心动词
塔利班官员与阿富汗活动家在多哈。他们正在为内部阿富汗峰会做准备。塔利班在阿富汗加兹尼市国家安全局办公室附近引爆了一枚汽车炸弹。爆炸导致至少 14 人死亡,超过 180 人受伤,其中包括许多附近学校的学生。	1. 塔利班 2. 官员 3. 与 47. 学校 48. 的 49. 学生	1. 塔利班官员与阿富汗活动家在多哈。他们正在为内部阿富汗峰会做准备。 2. 塔利班在阿富汗加兹尼市国家安全局办公室附近引爆了一枚汽车炸弹。 3. 爆炸导致至少 14 人死亡,超过 180 人受伤,其中包括许多附近学校的学生。	1. 在 2. 做准备 3. 引爆 4. 死亡 5. 受伤
The suicide bomber detonated his explosive-laden vehicle in the middle of the playground where spectators were watching a volleyball match in the ShahHasankhel village, about 25km off Lakki Marwat. Over a dozen houses were destroyed in the blast, rendering the residents homeless. Another 30 houses were damaged. An eight-foot-deep crater was created at the site of the blast.	1. 自杀式 2. 袭击者 3. 在 4. 沙阿哈桑凯尔村 55. 8 英尺深 56. 的 57. 弹坑 58. 。	1. 自杀式袭击者在距离拉基马尔瓦特约 25 公里的沙阿哈桑凯尔村的操场中央引爆了他的载有爆炸物的车辆。 2. 当时观众正在沙阿哈桑凯尔村的操场观看排球比赛。 3. 爆炸导致十余所房屋被摧毁,居民无家可归。 4. 另有 30 所房屋受损。 5. 爆炸现场形成了一个 8 英尺深的弹坑。	1. 引爆 2. 观看 3. 摧毁 4. 受损 5. 形成

通过对比表中传统分词结果和意义段拆分结果,可以发现传统分词方法仅从语法角度进行拆分,而意义段拆分方法能按照文本语义结果进行拆分,是更符合框架的拆分方法。

2.2.3 事件动作单元识别智体

事件动作单元识别智体 (Event Action Recognition Agent, EA-RA) 是事件要素提取的核心智体,其核心目标是从 TSA 输出的文本段 T_i 中精准识别事件核心动词,并通过 LLM 迭代验证机制提升识别精度。

EA-RA 首先调用分词工具,对文本段 T 进行分词得到词汇列表 $L_T = \{t_1, t_2, \dots, t_n\}$ 。在此基础上,调用 LLMs 对词汇列表 L_T 中每一个词汇单元 t_i 进行评价,输出 t_i 属于事件核心动词的概率 $p_i = LLMs(P(t_i))$ 。设定概率阈值 θ_{EA-RA} ,筛选出 $p_i \geq \theta_{EA-RA}$ 的词汇单元构

成初始候选集 $V^{(0)}$,即:

$$V^{(0)} = \{v \mid v = t_i, LLMs(P(t_i)) = p_i \geq \theta_{EA-RA}, 1 \leq i \leq n\} \quad (1)$$

为排除高频非事件动词,EA-RA 调用 LLMs 对第 $k-1$ 次迭代后的候选集 $V^{(k-1)}$ 中每个动词 v 进行事件主旨相关性评分:

$$s(v, T) = LLMs(P(v, T)), s \in [0, 1] \quad (2)$$

值 s 越高表示 v 与文本段 T 的事件主旨关联越紧密。设定评分阈值 δ ,筛选出 $s \geq \delta$ 的动词构成第 k 次迭代后的候选集 $V^{(k)}$,即:

$$V^{(k)} = \{v \mid v \in V^{(k-1)}, s(v, T) \geq \delta, k \geq 1\} \quad (3)$$

当两次连续迭代的候选集差异度小于收敛阈值 η 时,迭代终止。通过上述迭代式算法,EA-RA 筛选出事件核心动词,为后续建图工作提供高质量语料

$V^{(k)}$ 。

2.3 图谱构建多智能体

图谱构建多智能体的核心目标是基于事件提取多智能体输出的事件动作单元与语义关联信息,实现事件骨架图的结构化生成、逻辑修正与有效性验证。其内部通过图生成智体(Graph Generating Agent, GGA)、图理解智体(Graph Understanding Agent, GUA)、图修

改智体(Graph Modification Agent, GMA)与图验证智体(Graph Validation Agent, GVA)的协同交互,构建“子图拆解-结构优化-有效性验证”的闭环式图谱生成流程,确保最终事件骨架图满足时序逻辑一致性与语义关联完整性两大核心约束。图谱构建多智能体内部协作示意如图3所示。




图3 图谱构建多智能体内部协作图

2.3.1 图生成智体

图生成智体(Graph Generating Agent, GGA)主要工作为总结事件提取多智能体的提取结果,以大语言模型的语言建模能力为驱动,初步构建面向文档的单事件流程图。GGA通过读取EA-RA生成的动词集合 $V^{(k)}$ 和TSA生成的文本段集合 T ,利用LLMs语义能力直接生成初始事件图 $G^0 = (V^0, E^0)$ 。

2.3.2 图理解智体

图理解智体(Graph Understanding Agent, GUA)的核心功能是对输入的事件图进行语义层面的子图划分,通过聚焦局部语义单元降低后续图修改的复杂度,其核心是基于节点支撑文本语义相似度的层次聚类算法。设输入的初始事件图为 $G^0 = (V^0, E^0)$,其中 $V^0 = \{v_1^0, v_2^0, \dots, v_m^0\}$,每个节点 v_i^0 对应一个事件动作单元,如“策划袭击”或“安置爆炸物”,其支撑文本为 $S_i = \{s_{i1}, s_{i2}, \dots, s_{ik}\}$ 。令 $E^0 = \{e_{ij}^0 \mid 1 \leq i, j \leq m, i \neq j\}$ 为初始时序边集合, $e_{ij}^0 = 1$ 表示节点 v_i^0 在时序上先于 v_j^0 , $e_{ij}^0 = 0$ 表示无直接时序关联。为量化节点间的语义关联, GUA采用基于BERT^[30]的文本嵌入方法计算支撑文本的语义相似度。设 $Emb(S)$ 为支撑文本 S 的向量表示,则节点 v_i^0 与 v_j^0 的语义相似度定义为:

$$Sim(v_i^0, v_j^0) = \frac{Emb(S_i) \cdot Emb(S_j)}{\|Emb(S_i)\| \cdot \|Emb(S_j)\|} \quad (4)$$

$Sim(v_i^0, v_j^0)$ 值越大表示 v_i^0 和 v_j^0 两节点语义关联越紧密。在此基础上, GUA采用聚合式层次聚类对 V^0 进行聚类。初始时每个节点 v_i^0 视为一个独立聚类 $C_i = \{v_i^0\}$,此后进行迭代聚合操作,计算所有聚类对 (C_a, C_b) 的类间平均相似度:

$$Sim(C_a, C_b) = \frac{1}{|C_a| \cdot |C_b|} \sum_{v_i \in C_a} \sum_{v_j \in C_b} Sim(v_i, v_j) \quad (5)$$

基于上述类间平均相似度的计算结果,选取相似度最高的聚类对进行合并以生成新的聚类单元,并迭代执行此合并操作。当当前所有聚类对中相似度最大值低于阈值 α_{GUA} 时,中止聚类算法。通过该算法,最终得到子图集合 $G_{sub} = \{G_1^{sub}, G_2^{sub}, \dots, G_n^{sub}\}$, $G_p^{sub} = (V_p^{sub}, E_p^{sub}, T_p^{sub})$,其中 T_p^{sub} 为子图 G_p^{sub} 所属支撑文本信息,用于建立子图结构与原始情报文本语义间的对应关系。

2.3.3 图修改智体

图修改智体(Graph Modification Agent, GMA)的核心功能是基于原始文本的意义段与子图的语义匹配关系,生成图结构修改意见,修正初始图与文本语义的

偏差。为识别文本有但子图缺失的语义信息, GMA 首先计算子图集合 G_{sub} 与意义段 M_q 的语义匹配度, 定义为:

$$Match(G_{sub}, M_q) = \max_{1 \leq p \leq n} LLMs(P(T_p^{sub}, M_q)) \quad (6)$$

其中 $P(T_p^{sub}, M_q)$ 为提示词模板, 提示模型评估事件子图支撑文本 T_p^{sub} 与文本意义段 M_q 的语义一致性, 并输出 0 到 1 之间的评分 $Match(G_p^{sub}, M_q)$ 。若 $Match(G_p^{sub}, M_q) < \beta_{GMA}$, 则判定该子图存在语义缺口。针对语义缺口, GMA 通过 LLMs 生成修改意见集合 $O = \{o_1, o_2, \dots, o_t\}$, 每个修改意见 o_k 包含操作类型、操作对象及语义置信度。修改意见的置信度定义为归一化后的评分:

$$Conf(o_k) = \frac{LLMs(P(o_k))}{\max_{o \in O} LLMs(P(o))} \quad (7)$$

其中 $LLMs(P(o_k))$ 为 LLM 对修改意见 o_k 是否符合文本语义的评分, $Conf(o_k) \in [0, 1]$, 值越大表示该意见的语义合理性越高。基于修改意见集合 O , GMA 采取贪心策略优先采纳高置信度意见, 逐步对图进行修改, 并丢弃与已执行意见冲突的后续意见。

2.3.4 图验证智体

图验证智体 (Graph Validation Agent, GVA) 的核心功能是, 依托 Python 的 NetworkX 图分析库实现约束验证, 从时序无环性与语义连通性校验 GMA 输出的候选事件图的合规性, 并向 GMA 和 GUA 反馈优化方向。设采纳 GMA 修改意见后的候选图为 $G' = (V', E')$, 其中 $V' = V^0 \cup V_{new}$, $E' = (E^0 \cup E_{new}) \setminus E_{del}$, V_{new} 为新增节点, E_{new} 为新增边, E_{del} 为删除边。首先, 时序无环性要求确保候选图核心事件链连通, 因此定义连通性指标:

$$Conn(G') = \left(\frac{|\max_c |C_c| |}{|V'|} \right) \quad (8)$$

其中 C 为 G' 的连通分量集合, $|\max_c |C_c| |$ 为最大连通分量的节点数。若 $Conn(G') < \gamma_{GVA}$, 则计算各连通分量间的关联置信度: $Conf(C_a, C_b) =$

$$\max_{v_i \in C_a, v_j \in C_b} Sim(v_i, v_j) \quad (9)$$

并将置信度最高的分量对 (C_a^*, C_b^*) 反馈至 GMA, 要求补充时序边以补全连通性。重复上述过程直到 $Conn(G') \geq \gamma_{GVA}$ 为止。其次, 语义连通性要求图在语义上符合逻辑, 即需确保 G' 为有向无环图。若 G' 可生成拓扑序列, 则判定无环。若存在有向环 L , 则计算环内每条边的时序置信度: $Conf(e'_{lm, ln}) =$

$$\frac{count(e'_{lm, ln})}{|G_{raw}|}, e'_{lm, ln} \in L \quad (10)$$

$count(e)$ 为边 e 在原始图中的出现次数, $|G_{raw}|$ 为原始图总数。删除置信度最低的边 e'_{min} , 直

至 G' 满足无环约束。

2.4 图融合算法

本文采用基于频率统计的加权图融合算法 (Frequency Statistics-based Weighted Graph Fusion Algorithm, FSW-GFA)。给定一组事件图集合 $G = \{G_1, G_2, \dots, G_n\}$, 其中每个图 $G_n = (V_i, E_i)$ 表示一个事件图, 算法旨在构建一个骨架图 $G_n = (V^*, E^*)$, 使得该骨架图能够反映输入图集合中的共同事件模式和时序关系。对于每个事件类型 t_j , 其归一化权重公式如下:

$$w_{node}(t_j) = \frac{count t_j}{|G|} \quad (11)$$

其中 $count t_j$ 表示该事件类型在所有图中的出现次数, $|G|$ 为输入图的总数量。类似地, 对于时序关系, 采用如下公式计算时序边权重:

$$w_{edge}(t_s, t_t) = \frac{count t_{(t_s, t_t)}}{|G|} \quad (12)$$

其中 $count t_{(t_s, t_t)}$ 表示从事件类型 t_s 到事件类型 t_t 的时序关系在所有图中的出现次数。为了平衡召回率和精确率, 算法采用了双重阈值过滤策略。节点过滤阈值定义为 $\tau_{node} = \max(1, |G| \times \theta_{node})$, 边过滤阈值定义为 $\tau_{edge} = \max(1, |G| \times \theta_{edge})$, 其中 θ_{node} 和 θ_{edge} 分别为节点和边的过滤阈值参数。通过设置相对较低的阈值, 算法能够保留在少数图中出现但可能具有重要语义价值的事件类型和时序关系, 从而优先提高召回率指标。

骨架图的构建过程分为节点添加和边添加两个主要阶段。在节点添加阶段, 算法遍历所有满足 $w_{node} \geq \tau_{node}$ 条件的事件类型, 为每个事件类型在骨架图中创建对应的节点, 并赋予相应的权重信息。在边添加阶段, 算法检查所有满足 $w_{edge} \geq \tau_{edge}$ 且源节点和目标节点都存在于骨架图中的时序关系, 为这些关系在骨架图中创建对应的边, 并赋予相应的权重信息。

3 实验

3.1 实验数据

为验证 MAU-GES 的有效性, 本文以 Li 等人^[4]构建的简易爆炸装置 (improvised explosive device, IED) 数据集作为实验测试基准, 该数据集涵盖多种类型的爆炸事件。为保持实验与现有研究的可比性, 本文参考黄凯等人^[9]的实验设置, 选取数据集内的三类典型事件作为核心评测对象, 具体包括: 通用简易爆炸装置事件 (General-IED)、车载简易爆炸装置事件 (Car-IED) 及自杀式简易爆炸装置事件 (Suicide-IED)。数据集的核心统计信息如表 2 所示。

表 2 IED 数据集规模统计

事件类型	训练集 图数量	验证集 图数量	测试集 图数量	总计 图数量	总文本 文件数
Suicide-IED	176	22	22	220	3823
Car-IED	75	9	10	94	1853
General-IED	88	11	12	111	1357
总计	339	42	44	425	7033

实验中事件类型的定义与映射严格遵循 DARPA KAIROS 领域本体规范^[4],该本体共包含 67 种标准事件类型,可确保实验过程中事件类型标注的一致性与语义准确性,避免因类型定义模糊导致的评测偏差。

3.2 评测方法

为客观量化 MAU-GES 框架生成的事件骨架图与测试实例事件图的语义一致性,本文参考 Jin 等人提出的方法^[21],选取事件匹配度(Event Match, EM)与事件序列匹配度(Event Sequence Match, ESM)两大核心指标开展评测。

3.2.1 事件匹配度(EM)

EM 指标聚焦事件类型提取准确性,用于评估模型生成的事件骨架图与测试实例事件图在事件类型上的契合度。设 E_{gen} 为模型生成的事件骨架图中包含的事件类型集合, E_{ref} 为测试实例事件图中包含的基准事件类型集合,则精确率和召回率计算公式如下所示:

$$P_{EM} = \frac{|E_{gen} \cap E_{ref}|}{|E_{gen}|}, R_{EM} = \frac{|E_{gen} \cap E_{ref}|}{|E_{ref}|} \quad (13)$$

EM 指标的最终得分为 F1 分数,即:

$$F1_{EM} = \frac{2 \times P_{EM} \times R_{EM}}{P_{EM} + R_{EM}} \quad (14)$$

3.2.2 事件序列匹配度(ESM)

ESM 指标聚焦时序关系构建合理性,用于评估模型生成的事件骨架图与测试实例事件图在短事件链时序逻辑上的一致性。ESM 指标以连续短事件链为匹配单元。设 S_{gen} 为模型生成的事件骨架图中所有长度为 2 或 3 的连续事件链集合, S_{ref} 为测试实例事件图中所有长度为 2 或 3 的连续基准事件链集合,则精确率和召回率计算公式如下所示:

$$P_{ESM} = \frac{|S_{gen} \cap S_{ref}|}{|S_{gen}|}, R_{ESM} = \frac{|S_{gen} \cap S_{ref}|}{|S_{ref}|} \quad (15)$$

ESM 指标的最终得分为 F1 分数,即:

$$F1_{ESM} = \frac{2 \times P_{ESM} \times R_{ESM}}{P_{ESM} + R_{ESM}} \quad (16)$$

3.3 模型效果实验

为系统验证 MAU-GES 框架在无监督事件骨架生成任务中的有效性,本文选取如下 4 类具有代表性的基线模型开展对比实验。

DoubleGAE 模型^[21]: DoubleGAE 先通过有向 GCN 编码器获取事件图潜变量的均值和方差,再依据

采样的潜变量以自回归范式恢复事件图,最后将从高斯噪声中采样的隐变量输入模型以得到事件模式。

时序事件图模型(TEGM)^[4]: TEGM 采用自回归方法,逐步生成事件及新生成事件与现有事件间的边,通过贪婪解码获取事件模式。

基于频率的采样模型(FBS)^[21]: FBS 先计算训练集中两事件类型间边的出现频率,初始构建无变的事件类型节点模式,再按边的出现频率采样事件类型对并添加边,重复该过程直至新边形成循环。

语义-结构融合模型(CSM)^[9]: 该模型包含事件图编码器与事件图解码器两大核心部分。编码阶段依次通过拉普拉斯位置编码捕捉图局部结构信息、多头注意力机制提取语义信息、GCN 挖掘全局结构信息,最后归纳事件分布;解码阶段从事件分布采样初始向量,迭代进行事件类别识别与时序边生成,最终得到事件骨架图。

实验中所有模型的评测均聚焦于事件骨架图的核心结构,仅对比事件类型节点集合及时序边关系,不涉及事件论元的抽取结果,以确保评测目标的一致性。实验中设置 $\theta_{EA-RA} = 0.3$, $\alpha_{CUA} = 0.4$, $\beta_{CMA} = 0.7$, $\gamma_{GVA} = 0.7$, $\theta_{node} = 0.05$, $\theta_{edge} = 0.05$ 。实验基于 Windows11 系统,采用 Python 作为 MAU-GES 框架搭建的基础语言,Python 版本号为 3.9.11。计算机硬件配置为 Intel i5-14600KF、NVIDIA 3070 Ti GPU、64GB 内存和 2TB 硬盘,多智能体基座大语言模型采用 GLM4.6。本文模型和上述模型的对比结果如表 3 所示。

表 3 模型效果对比

数据集	模型	$F1_{EM}$	$F1_{ESM}$	
			$L = 2$	$L = 3$
Suicide-IED	TEGM	0.609	0.174	0.048
	FBS	0.642	0.164	0.036
	DoubleGAE	0.709	0.290	0.095
	CSM	0.776	0.388	0.174
	MAU-GES($N_{doc} = 248$)	0.811	0.422	0.205
	TEGM	0.588	0.162	0.044
Car-IED	FBS	0.542	0.126	0.038
	DoubleGAE	0.674	0.259	0.081
	CSM	0.780	0.381	0.203
	MAU-GES($N_{doc} = 132$)	0.821	0.400	0.178
General-IED	TEGM	0.638	0.181	0.065
	FBS	0.617	0.149	0.064
	DoubleGAE	0.697	0.273	0.128
	CSM	0.789	0.389	0.155
	MAU-GES($N_{doc} = 168$)	0.801	0.462	0.181

如表 2 所示,MAU-GES 框架在仅采用部分情报文本的条件下,除 Car-IED 数据集的 $F1_{ESM}(L = 3)$ 指标外,其他所有指标相比前人研究平均提升 1.5% 到

18.8% ,证明了框架在识别事件类型和识别长链事件任务上的先进性。Car-IED 数据集在 $F1_{ESM}(L=3)$ 指标上的下降主要源于递进式图合并的边际递减效应。如图 4 所示,该数据集从性能峰值点到全合并增加了




图 4 图合并边际递减效应示意

3.4 LLMs 配置实验

多智能体框架的性能与 LLMs 的性能密切相关,故本实验旨在验证不同 LLM 配置对多智能体协作效果的影响,进而筛选出性能与效率均衡的多智能体构建方案。实验选取 GLM 系列^[29]中三类代表性模型作为基座候选:

旗舰型模型 GLM4.6:具备 3550 亿总参数,激活参数 230 亿,具有 128K 上下文,具备强语义理解与复杂逻辑推理能力,但计算成本较高。

推理模型 GLM-ZI:具备 128K 上下文和最大 32K 输出,具有思维链能力,计算成本低于 GLM4.6。

经济型模型 GLM-4-Flash (GLM-4-Flash-250A14):具备 128K 上下文和最大 16K 输出,计算效率高但复杂任务处理能力有限。

基于上述模型,设计四种多智能体构建方案,具体如下表 4 所示。

表 4 多智能体构建方案

方案	配置模式	基座选择
1	单一强模型	所有任务都使用 GLM4.6
2	单一推理模型	所有任务都使用 GLM-ZI
3	单一轻量模型	所有任务都使用 GLM-4-Flash
4	复合配置	长上下文任务(TSA、GMA、GGA)用 GLM4.6
		强推理任务(EA-RA、GUA)用 GLM-ZI 简单子任务(MED-EA、GVA)用 GLM-4-Flash

设置模型参数和前文模型效果实验相同,数据集采用 Suicide-IED 作为实验数据,在此条件下四种方案的性能对比结果如图 5 所示。

60.6% 的图,后期图引入的噪声序列导致精确率下降。这一现象表明当合并图数量超过最优点时,新增图的边际收益递减,在实际应用中应根据性能曲线选择最优合并点。

如图 5 所示,方案 1 在各指标总体水平上表现最好,方案 2 其次,方案 3 最落后。方案 4 在事件类型识别上和方案 1 达到同等水平,且随着 N_{doc} 的增加,在事件链识别指标上方案 4 逐渐超过方案 1。这意味着方案 4 中的模型分配方案使得模型能力和工作内容进行了有效对齐,这种对齐最后体现为事件链识别指标的提升。

图 5(d)重在分析性能边际效益分析,为实际部署提供了重要参考。实验结果显示,四种方案在初期($N_{doc} < 10$)均具有高边际效益,但在 N_{doc} 超过 40 后,边际效益快速衰减。这意味着在实际应用中,收集 30 到 40 个高质量事件图即可获得接近最优的性能,无需盲目追求大规模数据。另外,事件链识别相比事件类型识别需要更多数据支持,这要求在实际应用中对序列匹配任务给予更多数据支撑。

3.5 消融实验

为验证本文所提多智能体驱动的无监督事件骨架生成框架(MAU-GES)相较于传统简单提示工程的性能优越性,明确多智能体协作机制对事件骨架生成精度的核心贡献,本研究设计了针对性的消融实验,以单一语言模型+简单提示为技术路径构建基线框架,与 MAU-GES 框架进行直接对比。

基线模型(baseline)采用单轮提示-直接生成的简化范式,仅依赖大语言模型的基础生成能力完成事件骨架构建。模型将同一事件的多个待处理情报文本 $C = \{c_1, c_2, \dots, c_n\}$ 和事件本体分类方案 O 直接以文本形式提交给 LLMs,要求其从文本中提取出事件图,并且

调用 FSW-GFA 图融合算法得到合并后的事件骨架图。除 baseline 外,实验还设置 baseline +MED-EA 和 baseline +事件提取多智能体两组对照组,用于研究

MED-EA 智体、事件提取多智能体和图谱构建多智能体的效用。




图5 LLMs 配置实验

实验数据上,选取 Suicide-IED 数据集作为评测数据,事件本体分类方案仍采用 DARPA KAIROS 领域本体规范^[4]。评测指标上采用事件匹配度与事件序列匹配度作为核心量化指标。基座模型统一使用 GLM-4.6,取 $N_{doc} = 271$,其余参数和 3.3 中实验相同。消融实验结果如表 5 所示。

表5 消融实验效果

模型	$F1_{EM}$	$F1_{ESM}$	
		($L = 2$)	($L = 3$)
baseline	0.741	0.361	0.110
baseline +MED-EA	0.785	0.352	0.163
baseline +事件提取多智能体	0.793	0.391	0.189
MAU-GES	0.811	0.422	0.202

如表 5 所示,增加 MED-EA 后,基准模型在事件覆盖度指标上展现出大幅提升,说明 MED-EA 所进行的文本筛选工作对建图结果具有明显提升作用。baseline +事件提取多智能体模型和 MAU-GES 框架的对比结果显示,在增加图谱构建多智能体系统后,各项指标均体现出明显提升,长链识别效果指标 $F1_{ESM}$ 提升了 6.4%,这意味着图谱构建多智能体中 GVA、GMA 和 GUA 三者的迭代流程对事件骨架构建任务的效果提升具有重要意义。

3.6 建图效果分析

本节选取三个不同类型的 IED 袭击数据集,参考前文实验最优参数配置,进行了全量图谱构建实验,选取节点集合 $V = \{v_i \mid w_{node}(v_i) \geq \theta_{node} = 0.15\}$ 和边集合 $E = \{e_i = (v_i, u_i) \mid w_{edge}(e_i) \geq \theta_{edge} = 0.15\}$ 进行可视化,结果如图 6 所示。通过对生成的可视化事件流程图进行拓扑结构与语义路径分析,本文发现 MAU-GES 框架在核心事件识别以及领域模式发现方面均有着良好表现。

从宏观拓扑结构来看,三类事件图谱均呈现出清晰的核心特征,所有图谱均以“攻击/袭击”为绝对中心枢纽,这符合恐怖袭击事件叙事的底层逻辑。此外,“识别/分类”节点在三个图中均作为次级核心出现,并与“攻击”节点形成强连接。这一现象表明,对事件性质的认知和确认是情报文本的重点之一。

从微观结构上看,模型较为敏锐地捕捉到了不同攻击类型特有的特征。相比起一般 IED 攻击而言,自杀式 IED 袭击中出现了“广播/声明”节点,准确还原了自杀式袭击常伴随恐怖组织认领责任的战术习惯。类似的,大规模汽车炸弹袭击图中,“运输/移动”节点的地位显著提升,不仅连接了“引爆/爆炸”,还与“阻碍/干扰”形成了关联。这种拓扑结构精准地映射了汽车炸弹的双重属性,既是高机动性武器,又是区域瘫

痪的战术阻碍工具。




图6 全量图谱构建效果图

4 结 语

本研究提出多智能体驱动的无监督事件骨架生成框架 MAU-GES,相较于现有依赖标注数据与分阶段流水线的事件骨架生成方法,在无监督、端到端、低资源适配性三个维度实现了显著突破,首次实现了在零标注数据条件下,从原始情报文本到标准化事件骨架图的端到端构建。本文通过多智能体的协同闭环,从根本上消除了信息抽取与图结构生成之间的语义断层。框架不仅摆脱了对标注数据与外部工具的依赖,更通过多智能体分工机制有效缓解了大语言模型在长文本处理中的上下文稀释问题,显著提升了低频事件环节的召回能力与整体骨架的时序逻辑一致性。

实验验证结果证明了框架的有效性。在简易爆炸装置 (IED) 数据集上,MAU-GES 在不使用全量数据的情况下,在事件匹配度指标与长链事件序列匹配度指标上超越 DoubleGAE、TEGM、CSM 等现有主流模型。LLMs 配置实验表明,复合模型分配方案可实现模型能力与任务需求的对齐,在保证精度的同时优化计算成本。消融实验进一步证实,多智能体协作机制对事件骨架生成精度的提升具有核心贡献,显著优于基于单一大语言模型的简单提示的基线方案。

本研究仍存在三方面局限:一是实验验证集中于爆炸事件领域,模型在医疗应急、金融风险等其他专业领域的泛化能力尚未充分测试,且未涉及多语言、多模态情报文本的处理场景。二是多智能体当前采用静态任务分配逻辑,面对超长文本或高噪声数据时,动态调整智能体分工的灵活性不足,可能导致处理效率下降。三是多智能体框架性能有限,处理大量文本时产生较高时间和算力开销。

未来研究可从三方面推进:其一,拓展数据集至多领域、多语言场景,结合领域知识图谱优化事件类型映射规则,提升模型跨场景适配性;其二,探索多模态情报文本的事件要素融合提取,丰富骨架图的语义维度;

其三,设计基于实时任务复杂度评估的动态调度算法,实现多智能体资源的按需分配,进一步平衡提取精度和计算成本的矛盾。

参 考 文 献

- [1] Wen H, Lin Y, Lai T, et al. Resin: A dockerized schema-guided cross-document cross-lingual cross-media information extraction and event tracking system [C]//Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies: Demonstrations, 2021: 133-143.
- [2] Chambers N, Jurafsky D. Unsupervised learning of narrative event chains [C]//Proceedings of ACL-08: HLT. 2008: 789-797.
- [3] Huang L, Cassidy T, Feng X, et al. Liberal event extraction and event schema induction [C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2016: 258-268.
- [4] Li M, Li S, Wang Z, et al. The future is not one-dimensional: Complex event schema induction by graph modeling for event prediction [J]. arXiv preprint arXiv:2104.06344, 2021.
- [5] Lin Y, Ji H, Huang F, et al. A joint neural model for information extraction with global features [C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020: 7999-8009.
- [6] Zhu F, Zhang L, Gao J, et al. A diffusion model for event skeleton generation [J]. arXiv preprint arXiv:2305.17458, 2023.
- [7] Hao Y, Cao P, Chen Y, et al. Complex event schema induction with knowledge-enriched diffusion model [C]//Findings of the Association for Computational Linguistics: EMNLP 2023, 2023: 4809-4825.
- [8] Chang M, Fokoue A, Uceda-Sosa R, et al. CHRONOS: A schema-based event understanding and prediction system [C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(21): 22871-22877.
- [9] 黄 凯, 马廷淮, 孙圣杰, 等. 语义信息提取和图结构挖掘的事件骨架生成方法 [J]. 计算机工程与应用, 2025, 61(12): 187-195.

- [10] Sheng Y. Research progress of named entity recognition based on Large Language model [Z] (2024 - 01 - 01).
- [11] Luo Z, Yang Y, Qi R, et al. Incorporating Large Language-models into named entity recognition: Opportunities and challenges [C]. 2023 4th International Conference on Computer, Big Data and Artificial Intelligence (ICCBD+AI), 2023: 429 - 433.
- [12] Yang S, Li M, Xu L. Named entity recognition based on Large Language model and instruction tuning [C]//2024 5th International Conference on Big Data & Artificial Intelligence & Software Engineering (ICBASE), IEEE, 2024: 336-343.
- [13] Li Q, Xie T, Zhang J, et al. Enhancing named entity recognition with external knowledge from large language model [J]. Knowledge-Based Systems, 2025, 318: 113471.
- [14] Wu J, Xu J, Liu X, et al. Causal representation enhances cross-domain named entity recognition in Large Language models [J]. Computers, Materials & Continua, 2025, 83(2): 2809 - 2828.
- [15] Ferreira Cruz A, Rocha G, Lopes Cardoso H. Coreference resolution: Toward End-to-End and cross-lingual systems [J]. Information, 2020, 11(2): 74.
- [16] Wan B, Dong S, Chu D, et al. A deep neural network model for coreference resolution in geological domain [J]. Information Processing & Management, 2023, 60(3): 103268.
- [17] Li H, Li S, Hao F, et al. BoostER: Leveraging Large Language models for enhancing entity resolution [J]. arXiv, 2024.
- [18] Balluff P, Boomgaarden H G, Waldherr A. Automatically finding actors in texts: A performance review of multilingual named entity recognition tools [J]. Communication Methods and Measures, 2024, 18(4): 371 - 389.
- [19] Theptakob N, Seneewong Na Ayutthaya T, Saetia C, et al. A cross-document coreference resolution approach to low-resource Languages [M]//Lecture Notes in Computer Science. Springer Nature Switzerland, 2023: 422 - 431.
- [20] Li C, Wang G, Cao J, et al. A nested named entity recognition model based on multi-agent communication mechanism (Student Abstract) [C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(18): 15823-15824.
- [21] Jin X, Li M, Ji H. Event schema induction with double graph autoencoders [C]//Proceedings of the 2022 conference of the North American chapter of the Association for Computational Linguistics: Human Language Technologies, 2022: 2013-2025.
- [22] Cemri M, Pan M Z, Yang S, et al. Why do multi-agent llm systems fail? [J]. arXiv preprint arXiv:2503.13657, 2025.
- [23] Guo T, Chen X, Wang Y, et al. Large language model based multi-agents: A survey of progress and challenges [J]. arXiv preprint arXiv:2402.01680, 2024.
- [24] Swanson K, Wu W, Bulaong N L, et al. The virtual lab: Ai agents design new sars-cov-2 nanobodies with experimental validation [J]. bioRxiv, 2024: 2024. 11. 11. 623004.
- [25] Qian C, Liu W, Liu H, et al. Chatdev: Communicative agents for software development [J]. arXiv preprint arXiv: 2307. 07924, 2023.
- [26] Fournay A, Bansal G, Mozannar H, et al. Magentic-one: A generalist multi-agent system for solving complex tasks [J]. arXiv preprint arXiv:2411.04468, 2024.
- [27] Wang Z, Zhao Z, Lyu Y, et al. A cooperative multi-agent framework for zero-shot named entity recognition [C]//Proceedings of the ACM on Web Conference 2025. 2025: 4183 - 4195.
- [28] Chowdhery A, Narang S, Devlin J, et al. Palm: Scaling language modeling with pathways [J]. Journal of Machine Learning Research, 2023, 24(240): 1-113.
- [29] GLM T, Zeng A, Xu B, et al. Chatglm: A family of large language models from glm-130b to glm-4 all tools [J]. arXiv preprint arXiv:2406.12793, 2024.
- [30] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding [C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171 - 4186.